

Matriz de Optimización de Costos

Triage de Leads — Taller de Reparación de PC

1. Qué modelo se usa en cada tarea

El sistema tiene un único punto de inferencia de IA (clasificar + diagnosticar), por lo que la decisión de modelo se concentra ahí. Se eligió un modelo de gama media-alta (Claude Sonnet) en lugar de uno económico, porque la tarea combina dos exigencias a la vez: clasificación estructurada (fácil, resoluble con un modelo económico) y redacción de un diagnóstico técnico coherente a partir de una descripción ambigua del cliente (una tarea de lectura densa y razonamiento, donde un modelo económico tipo GPT-4o-mini tiende a dar diagnósticos genéricos o poco útiles).

Tarea	Modelo elegido	Justificación
Clasificar prioridad + generar diagnóstico técnico	Claude Sonnet (vía n8n AI Gateway)	Tarea de lectura densa: exige interpretar una descripción libre y ambigua del cliente y devolver un diagnóstico técnico coherente, no solo una etiqueta.
(Si se separara en el futuro) Solo triage de prioridad	GPT-4o-mini o equivalente económico	Clasificar alta/baja por palabras clave o señales simples no requiere razonamiento denso; un modelo económico alcanza y reduce costo por lead.
Reprocesamiento masivo (ej. cola de leads sin responder de la semana)	Message Batches API (mismo modelo, -50%)	No requiere respuesta en segundos; agrupar en lote aprovecha el descuento del 50% de Anthropic.

2. Control de costos aplicado en el nodo actual

Se limitó el parámetro Max Tokens de la respuesta a un valor bajo (400), ya que el diagnóstico esperado es breve (2-4 líneas) y no hay motivo para permitir respuestas más largas y costosas. Durante las pruebas del sistema, el consumo real registrado en el saldo de créditos gestionados por n8n (AI Gateway) fue de aproximadamente USD 0,06 de un total de USD 2,00 disponibles, tras varias ejecuciones de prueba — lo que confirma que, para el volumen esperado de un taller (decenas de consultas por semana, no miles), el costo de inferencia es marginal y no justifica migrar a un modelo más económico por ahora.

3. Cuándo migrar a Batch API

El triage de leads en tiempo real (un cliente esperando respuesta) no es candidato a Batch, porque Batch responde en una ventana de hasta 24 horas. El escenario donde sí aplicaría es un proceso aparte y no urgente: por ejemplo, reprocesar al final del día todos los leads que quedaron sin diagnóstico por un error de la API (los que caen en la tabla Errores), agrupándolos en un solo lote nocturno con 50% de descuento, en vez de reintentarlos uno por uno en tiempo real.